

由于我英语方面比较薄弱，所以大部分都是阅读中文的参考文献

Qwen 部署：

[QwenLM/Qwen3: Qwen3 is the large language model series developed by Qwen team, Alibaba Cloud.](#)

Qwen 的 github 官方开源网站，利用 SGLang 启动兼容 OpenAI 的 API 服务服务器时用到的指令是通过这里更改的

官方指令：

```
python -m sglang.launch_server --model-path Qwen/Qwen3-8B --port 30000 --context-length 131072 --reasoning-parser qwen3
```

我修改后：

```
python -m sglang.launch_server \  
    --model-path ~/models/Qwen3-0.6B \  
    --host 0.0.0.0\  
    --port 30000 \  
    --context-length 8192 \  
    --mem-fraction-static 0.70 \  
    --reasoning-parser qwen3
```

使用 Anaconda 作为 python 环境之间的管理：

[Anaconda 教程 | 菜鸟教程](#)

大多数都是在命令行实现，学习了基础的 conda 指令，学会了配置不同环境和管理环境

Pip:

[Python3 pip | 菜鸟教程](#)

学习了 pip 的用处和基本指令

Mooncake:

[kvcache-ai/Mooncake: Mooncake 是 Kimi 的服务平台，Kimi 是由 Moonshot AI 提供的领先大型语言模型服务。](#)

但是大部分不是很理解

关于大模型部署的其它相关知识：

[datawhalechina/self-llm: 《开源大模型食用指南》针对中国宝宝量身打造的基于Linux 环境快速微调（全参数/Lora）、部署国内外开源大模型（LLM）/多模态大模型（MLLM）教程](#)

其它部分通过 b 站视频学习，例如 wsl2+ubuntu 的安装，Sglang 的相关介绍等