

作业感受

1. 简述下你是如何完成第二次挑战的。(例如, 如何使用 AI、如何工作迭代等方面)

本次挑战我依旧使用了第一次挑战的 ai, 工作迭代: 先通过 ai 学会 /generate 和 /flush_cache 如何使用和其作用, 再通过 b 站一些视频理解了 Transformer 和 KV Cache 的原理, 然后开始让 ai 帮我生成相应的代码和通过简单的指令进行实现, 然后是阅读 SGLang 关于 /generate 主线所使用到主流程代码, 还是比较难懂的。

2. 你觉得哪部分工作最困难, 你是如何克服这个困难的。

主要是理解代码有点困难了, 因为只有 C/C++ 和 Java 基础没有 python 语言基础再加上时间紧迫代码太多, 只能通过 claude 辅助, 把需要阅读的主要代码找出来, 以及把 python 代码用 C++ 或者 Java 语法来解释, 还是可以大致理解的。以及理解 KV 缓存原理也是个难点, 通过 b 站进行了学习

3. 你觉得类似的从 0 到 1 的科研工作, 需要包含哪些方面的研究, 对你今后的科研工作有什么启发

需要学会在别人的架构上提出新假设和新架构, 就像 SGLang 正是在前面一些其它架构的基础上创新, 提出 RadixCache 的树状 KV 复用, 大大提高了 token 的计算速率, 科研不仅是造轮子, 也是优化轮子的过程。