

挑战三：比较并改进 RayServe 路由

搭建四副本服务

每人预约四张 GPU，在同一台服务器上启动四个相同配置的 SGLang 服务，并建立 1 个 Rayhead 节点和 4 个逻辑 worker 节点。部署四个 Ray Serve Replica，使每个 Replica 位于不同的 worker 节点，并固定转发到一个 SGLang 服务。

Client-> Ray Serve HTTP Proxy-> Replica 0..3-> SGLang 0..3

可使用 `ray.cluster_utils.Cluster` 创建逻辑节点，无需容器或 `sudo` 权限。Ray Serve 负责选择 Replica，SGLang 负责组批、推理和 KVCache；本实验不评价跨服务器网络与共享存储性能。服务接口和响应头要求以固定负载目录的 README 为准。

使用固定负载

下载并校验课程负载：

```
git clone https://github.com/Zirkland/26fall-HW-data.git
```

```
cd 26fall-HW-data/workloads/hw2/target3-routing-policies
```

```
python-m pip install-r requirements.txt
```

```
python validate_workload.py mooncake_prefix_workload_v2_seed2026.jsonl
```

校验结果应包含 64 个前缀族、64 条预热请求和 2048 条测量请求。负载由 MooncakeFAST'25tool-agent trace 派生，包含 steady、burst 和 recovery 三个阶段，以及一个用于形成热点的高频前缀族。A-D 必须使用仓库中发布的同一文件，不得修改请求、到达时间或顺序。完整数据说明、回放命令和输出字段见负载目录中的 README。

完成四组对照

所有实验通过同一个 RayServeHTTP 入口回放，并保持模型、SGLang 参数、副本拓扑和压测端配置一致。每轮开始前重新部署对应的 RayServe 配置，清空四个 SGLang 后端的缓存，再由流量发生器完成预热和测量。

组别	配置
A: 默认 P2C	默认请求路由器, max_ongoing_requests=5
B: 调优 P2C	测试两个非默认的 max_ongoing_requests 值
C: 纯前缀亲和	ConsistentHashRouter, num_fallback_replicas=0; 使用 B 中选出的参数
D: 改进路由	使用 B 中选出的参数, 在前缀复用与负载均衡之间作出权衡

组 B 根据吞吐量与延迟选择一个参数。组 C 用于观察前缀亲和带来的缓存收益和热点偏斜。组 D 在 RayServe 的扩展接口上完成一个可运行的改进即可, 例如优先选择前缀亲和副本, 并在其负载较高时使用其他副本; 无需实现完整论文算法。路由器只能使用当前请求和当前服务状态, 不得查看未来请求。

分析结果

目标三主表列出 A、两个 B 候选、C 和 D 的成功率、吞吐量、缓存命中率、实际 Prefill token 数、TTFTp95、端到端延迟 p95, 以及四个 SGLang 后端的请求分布。本作业不规定实验轮数; 如对同一配置进行多次实验, 应说明轮次, 并如实呈现结果波动。其余逐请求指标和分阶段结果保留在原始文件中, 按需用于解释突发排队或热点, 无需全部放入正文。

结合数据回答: 默认值与 B 中选定值为何表现不同; 前缀亲和为什么同时带来缓存收益和热点; D 使用了哪些信号与规则, 改善了什么, 又付出了什么代价。client_queue 和 dispatch_lag 仅用于确认压测端没有成为主要瓶颈。

完成标准: 1 个 head 节点和 4 个 worker 节点均处于活跃状态; 四个 Replica 分别访问四个独立的 SGLang 后端; 每轮 2048 条测量请求成功且完整返回。D 的代码可以复现, 分析与数据一致, 不要求所有指标最优。

AI 使用说明情况

使用的 AI 模型, 使用的 AI 提示词, AI 如何帮助你学习以及在运用 AI 时是否被误导

作业感受

- (1) 简述下你是如何完成第三次挑战的。(例如, 如何使用 AI、如何工作迭代等方面)
- (2) 你觉得哪部分工作最困难, 你是如何克服这个困难的。(禁止 AI 辅助撰写)
- (3) 你觉得类似的从 0 到 1 的科研工作, 需要包含哪些方面的研究, 对你今后的科研工作有什么启发(禁止 AI 辅助撰写)

交付格式

在 github 上上传 HW3-姓名（或学号）.zip，解压后仅包含同名根目录：

HW3-姓名（或学号） /

```
├── README.md
├── report.pdf
├── AI 使用说明情况（第三次挑战）.pdf
├── src/
│   ├── target1/
│   │   └── target3/
│   └── results/
│       ├── target1/
│       │   ├── shared_prefix/
│       │   └── dispersed_prefix/
│       └── target3/
│           ├── A_default/
│           ├── B_candidates/
│           ├── C_affinity/
│           └── D_improved/
```

如对同一配置进行多次实验，可在对应目录下自行建立 run-1/、run-2/ 等子目录。

- README.md：写明 GPU 与软件版本、安装方法、启动与回放命令、脚本用途，以及结果目录与报告表格的对应关系。
- report.pdf：包含本次挑战的实验、流程图和分析。
- src/：包含负载脚本、Ray 集群与 Serve Deployment、D 的路由代码、依赖和必要配置。代码应能按照 README 运行。
- results/：每轮由流量发生器生成的完整 CSV/JSON 文件。报告中的数据应能对应到原始结果。

请勿提交模型权重、Python 环境、软件安装包或缓存目录。

挑战截止时间：10.7 22:00

提交方式：群里面的收集表