

一．背景

本次挑战承接第一次挑战，本次挑战需完成任务：测量 SGLang 前缀缓存的效果，阅读一次请求的主要处理流程。

二．环境

统一使用 SGLang 0.5.14、Ray 2.56.0 和 Qwen/Qwen3-0.6B

三．挑战内容

任务一：测量前缀缓存

启动 SGLang，保持 Radix Cache 开启，通过原生 /generate 接口发送 input_ids，并使用流式响应。自行构造两组负载，每组包含 32 条测量请求，最大并发数为 8。统一设置 temperature=0、max_new_tokens=16、ignore_eos=true 和 sampling_seed=2026。

负载	输入结构	测量前准备
共享前缀	2048 个 token 的共享前缀和 64 个 token 的独立后缀	发送 1 条包含共享前缀的预热请求
分散前缀	输入长度均为 2112 个 token，且首个 token 各不相同	不进行前缀预热

首次实验前先用短请求完成服务预热。每组测量前等待已有请求结束，调用 POST /flush_cache 并确认成功；共享前缀组再发送表中的预热请求。预热请求不计入结果。除前缀能否复用外，两组的模型、输入与输出长度、请求顺序和并发数均保持一致。

主表记录成功率、吞吐量、缓存命中率、实际执行 Prefill 的 token 数，以及 TTFT、TPOT 和端到端延迟的 p50、p95。其中：

缓存命中率 = $\text{sum}(\text{cached_tokens}) / \text{sum}(\text{prompt_tokens})$

实际 Prefill token 数 = $\text{sum}(\text{prompt_tokens} - \text{cached_tokens})$

从因果自注意力公式出发解释前缀复用：

$$Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

结合因果掩码以及 $K_i = h_iW_K, V_i = h_iW_V$ ，说明相同 token 与位置的前缀为什么可以复用 K/V、命中后仍需计算哪些 token，以及 TTFT 与 TPOT 为什么呈现不同变化。

完成标准：两组测量请求均全部成功，且输入、输出长度一致；共享前缀组具有更高

的缓存命中率和更少的实际 Prefill token。提交对照表，并根据公式和数据解释差异。

任务二：阅读 SGLang 请求流程

在第一次挑战 Pipeline 图的基础上阅读 SGLang v0.5.14 源码，沿以下主线追踪一条 /generate 请求：

TokenizerManager.generate_request

-> Scheduler.event_loop_normal / waiting_queue

-> get_new_batch_prefill / match_prefix_for_req

-> RadixCache.match_prefix

-> PrefillAdder / ScheduleBatch

-> model worker: Prefill, Decode

-> RadixCache.cache_finished_req / cache_unfinished_req

-> TokenizerManager: streaming output

在报告中提交一张流程图和不超过 1 页的说明，标出关键函数所在文件，并回答：请求如何进入等待队列；前缀匹配如何减少本轮 Prefill token；新产生的 KV 如何写回缓存；生成结果如何流式返回。本任务只关注主流程，无需逐行解释或修改 SGLang 源码。

完成标准：流程图覆盖请求接收、等待队列、前缀匹配、Prefill/Decode、缓存更新和流式输出；关键函数和文件位置能够在 v0.5.14 源码中找到。

四 . AI 使用说明情况

使用的 AI 模型，使用的 AI 提示词，AI 如何帮助你学习以及在运用 AI 时是否被误导

五，作业感受

(1) 简述下你是如何完成第二次挑战的。(例如，如何使用 AI、如何工作迭代等方面)

(2) 你觉得哪部分工作最困难，你是如何克服这个困难的。(禁止 AI 辅助撰写)

(3) 你觉得类似的从 0 到 1 的科研工作，需要包含哪些方面的研究，对你今后的科研工作有什么启发(禁止 AI 辅助撰写)

六．交付格式

1.在 github 仓库上上传 HW2-姓名.zip，解压后仅包含同名根目录：

HW2-姓名/

```
├── README.md
├── report.pdf
├── AI 使用说明情况（第二次挑战）.pdf
├── src/
│   ├── target1/
│   └── results/
│       ├── target1/
│       ├── shared_prefix/
│       └── dispersed_prefix/
```

如对同一配置进行多次实验，可在对应目录下自行建立 run-1/、run-2/ 等子目录。

- README.md：写明 GPU 与软件版本、安装方法、启动与回放命令、脚本用途，以及结果目录与报告表格的对应关系。
- report.pdf：包含两个任务的实验、流程图和分析，正文不超过 8 页。任务二的流程图和说明合计不超过 2 页。
- src/：包含代码，代码应能按照 README 运行。
- results/：保存目标一的逐请求结果与汇总，报告中的数据应能对应到原始结果。

提交截止时间：10.3 22:00

提交方式：群里面的收集表